COMPUTAÇÃO EM NUVEM

Data Lake & Analytics na AWS

600 × 400

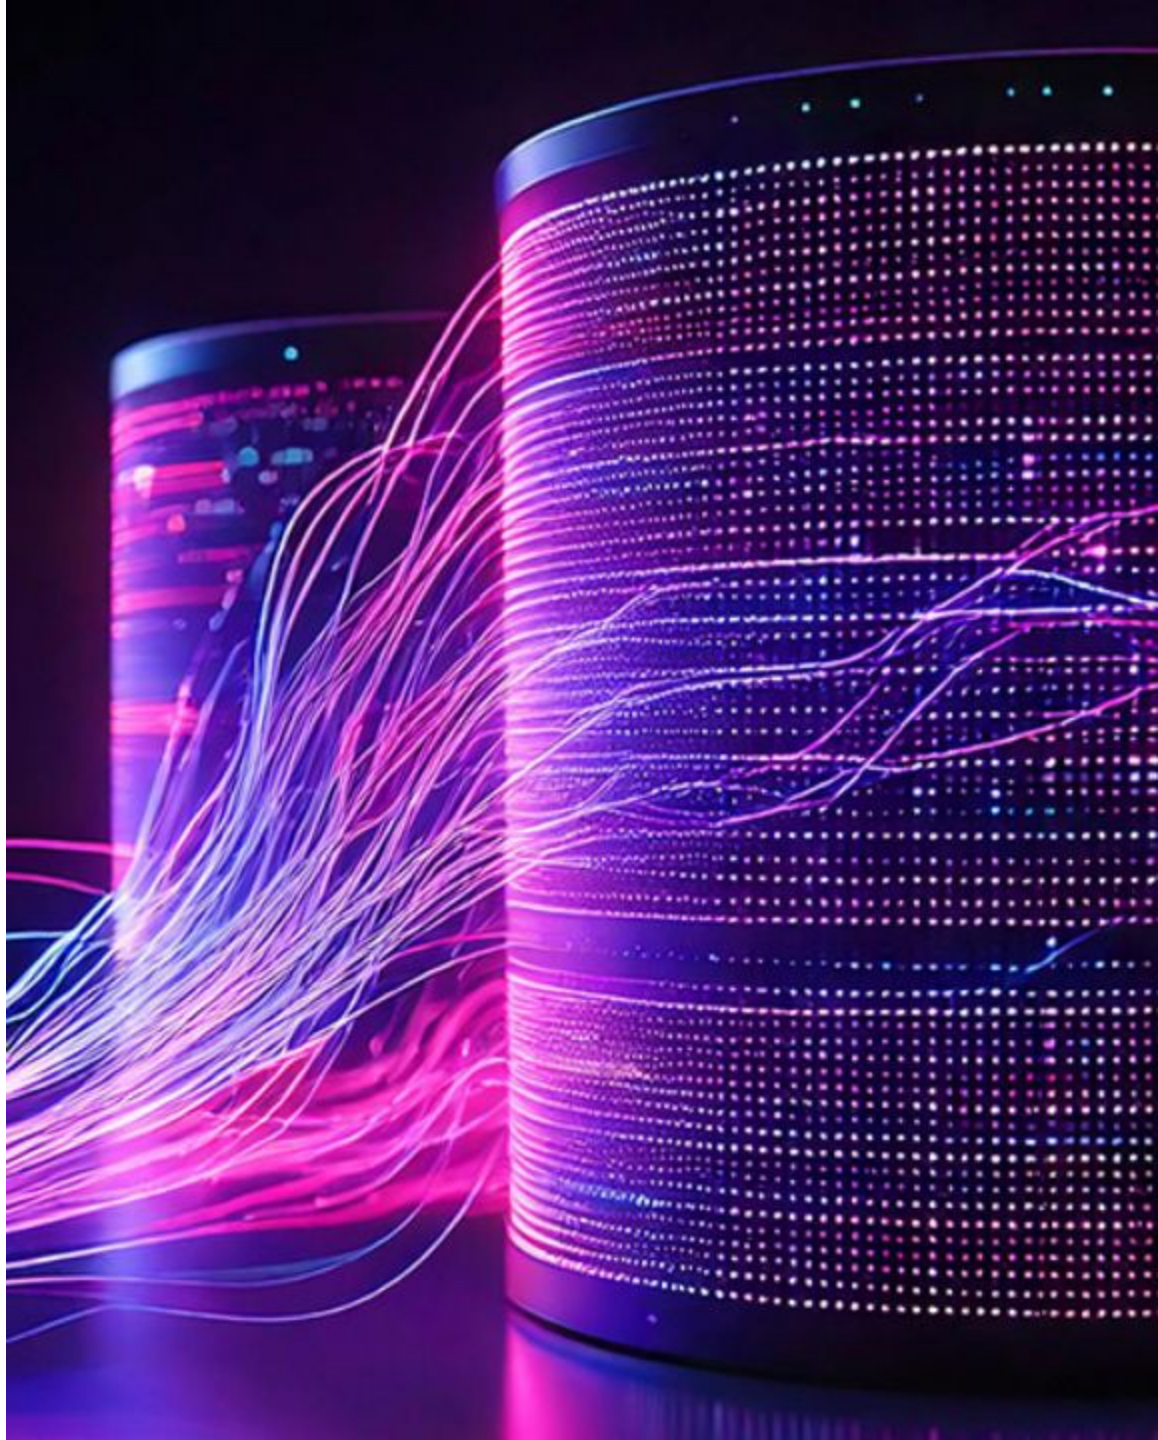
Do armazenamento bruto à inteligência de dados de alta performance.

MÓDULO 01

Introdução a Data Lakes

O que é um Data Lake?

- **Repositório centralizado: Única fonte da verdade.**
- **Múltiplos formatos: Dados estruturados, semi e não estruturados.**
- **Escala ilimitada: Armazenamento desacoplado do processamento.**



Terminologia na AWS



Buckets

Contêiner principal de alto nível.



Objetos

Arquivos, dados e seus metadados.



Prefixos

Estrutura lógica de pastas virtuais.

MÓDULO 02

Amazon S3

Armazenamento Escalável

A camada base onde todos os dados repousam.

11 Noves de durabilidade (99.999999999%).

Acesso puramente via API REST.



Arquitetura de Camadas (Prefixos)

Camada Raw

Dados brutos, formato original, sem alterações.



Camada Curated

Dados limpos, particionados (Parquet/ORC).

Segurança e Gestão de Custos



Controle de Acesso

Políticas de Bucket exclusivas.

Integração profunda com IAM Roles.



Lifecycle Rules

Transição automática para S3 Glacier.

Expiração de dados antigos programada.

MÓDULO 03

AWS Glue DataBrew

Data Profiling Automático

Avaliação instantânea de anomalias e completude sem escrever código.

100%
Visualização de schema.

Zero
Scripts de análise.

Limpeza No-Code

- 250+ transformações pré-construídas.
- Remoção visual de nulos e duplicatas.
- Aplicação de regras de qualidade estritas.



DataBrew vs. Glue ETL

Glue DataBrew

Totalmente visual e interativo.

Foco em higienização e analistas de dados.

Rápida criação de receitas prontas.

Glue ETL

Código programático (PySpark/Scala).

Foco em engenharia pesada e escala.

Transformações e joins complexos.

MÓDULO 04

AWS Glue

Data Catalog e Crawlers



O Metastore Central

Mapeia onde os dados estão e sua estrutura.



Crawlers Automáticos

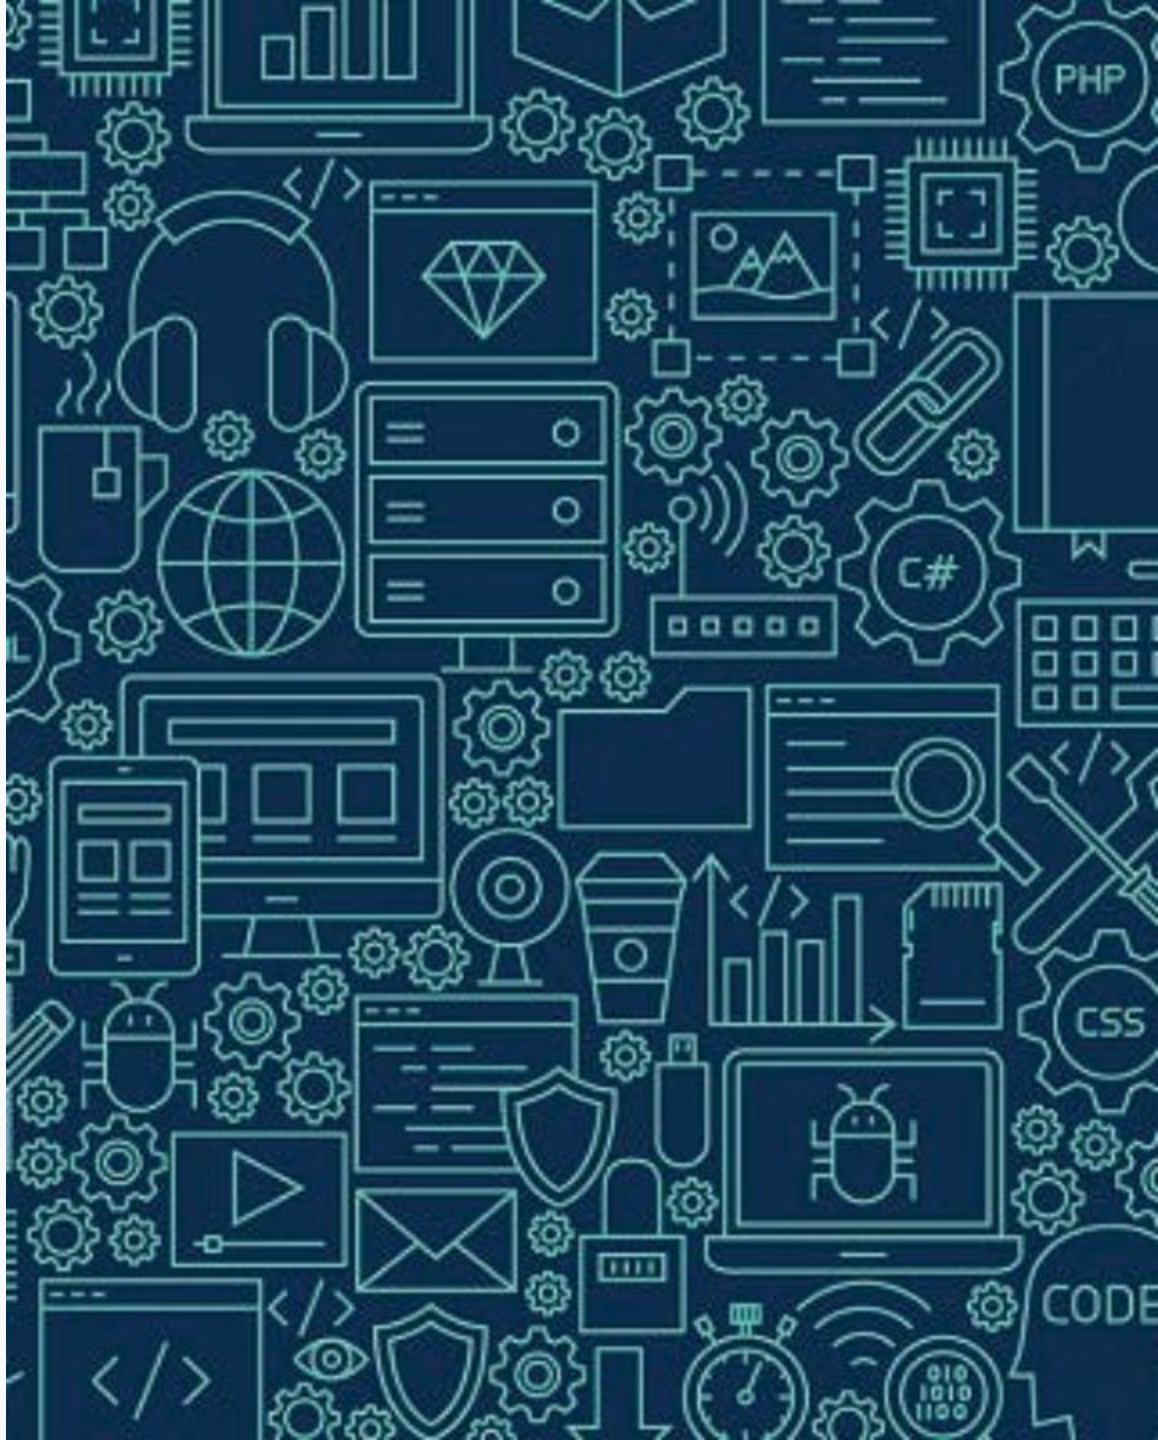
Inferência de schema lendo os arquivos no S3.

ETL Serverless

Execução via Apache Spark.

Zero infraestrutura. Sem servidores para gerenciar.

Escalonamento automático de recursos sob demanda.



Integração Nativa com S3

1. Leitura

Busca os dados raw instantaneamente.

2. Conversão

Transição de CSV/JSON para formato Parquet.

3. Gravação

Escrita particionada lógica na camada Curated.

MÓDULO 05

Amazon EMR



Ecossistema Big Data

Clusters gerenciados para frameworks abertos.

- **Apache Hadoop e Spark nativos.**
- **Processamento de petabytes.**
- **Integração nativa com Data Catalog.**

Dimensionamento e Controle Total

Master Node

Gerencia o cluster e o status das tarefas.

Core Nodes

Executam tarefas e armazenam dados locais.

Task Nodes

Apenas processamento. Escalabilidade rápida.



Limitações EMR: Learner Lab

Cotas severas de vCPU.

Muitos tipos de instâncias estão **bloqueados** para estudantes.

Por isso, prefira **AWS Glue** para laboratórios educacionais.

MÓDULO 06

Amazon Athena

SQL Direto no Data Lake

Consultas Ad-Hoc 100% Serverless.

Sem necessidade de mover dados ou gerenciar infraestrutura de banco.

Técnicas de Otimização

Particionamento

Filtra pastas específicas (ex: ano=2026).

Formatos Colunares

Uso estrito de Parquet ou ORC.

Compressão

Diminui drásticamente bytes lidos (Snappy/Gzip).

Modelo de Custos Athena

Bilhetagem puramente por consumo.



Cobrança por volume varrido.
Paga-se por Terabyte escaneado na query.

```
SELECT categoria, SUM(valor) FROM
"db_lake"."vendas" WHERE ano = '2026' GROUP BY
categoria;
```

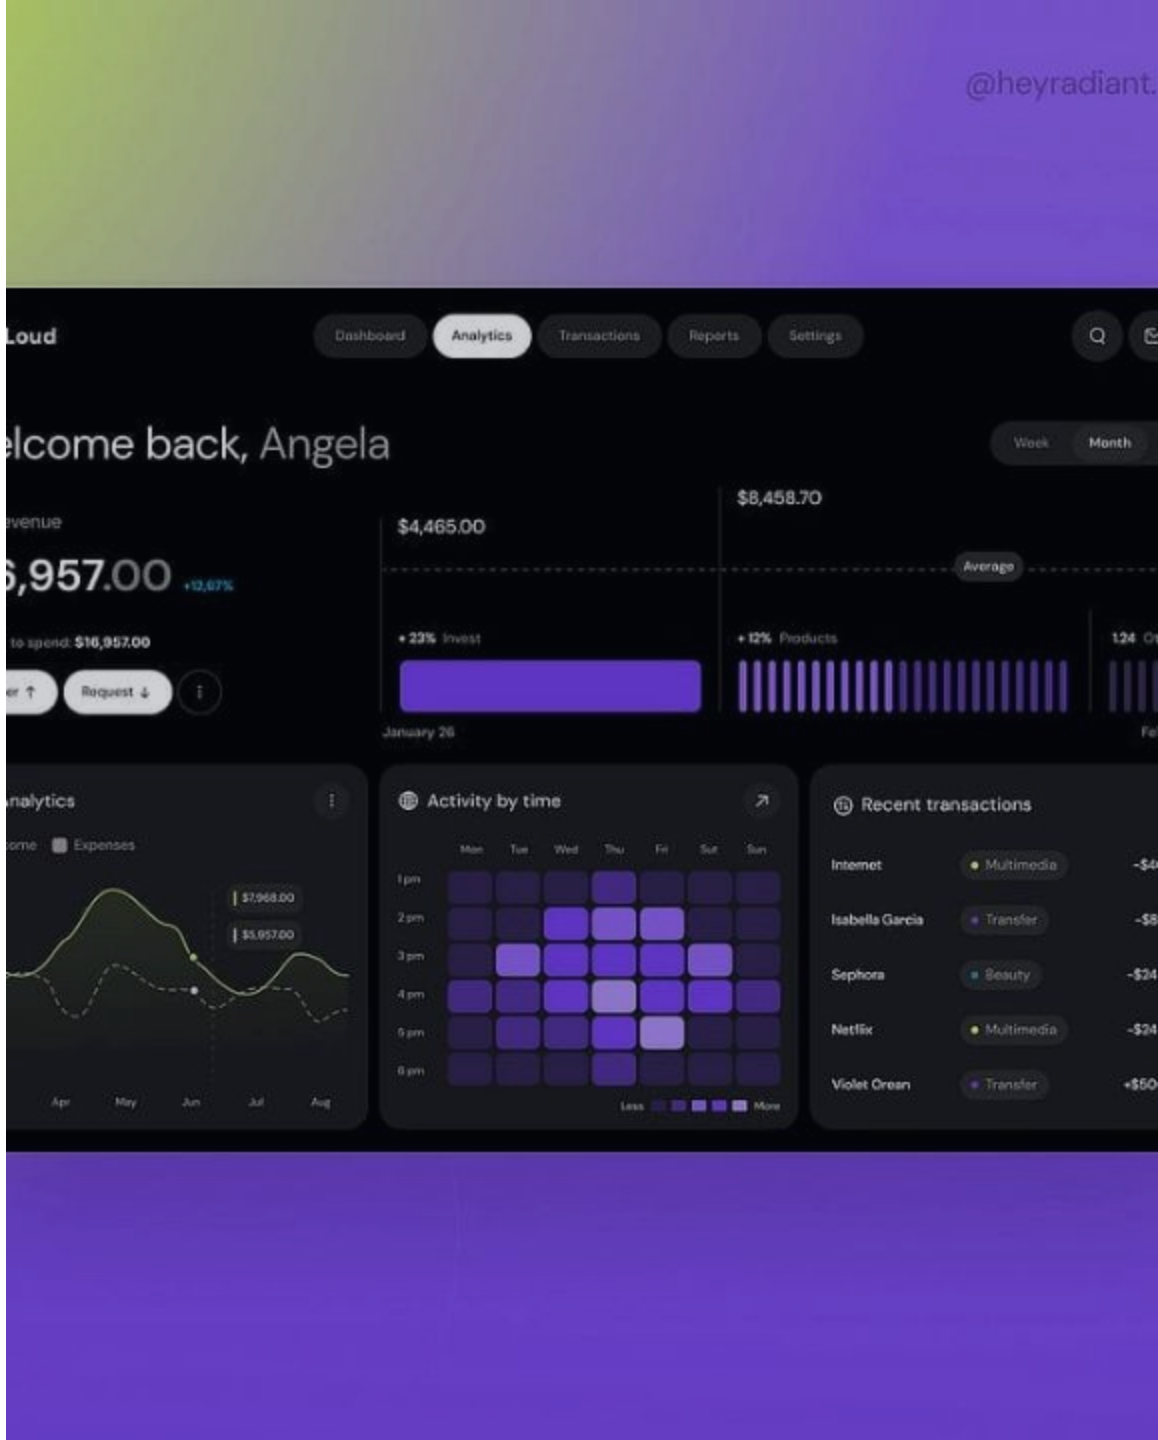
MÓDULO 07

Amazon Redshift

Data Warehouse OLAP

Desempenho máximo para modelagem estruturada.

- Cargas analíticas altamente complexas.
- Estrutura de dados totalmente colunar.
- Dashboards e Business Intelligence.



Redshift Spectrum



Consulta Estendida

Execute SQL nos dados do S3 diretamente do DW.



Sem Movimentação

Elimina a necessidade de rotinas lentas de carga física.

Decisão de Arquitetura

S3 + Athena

Alta flexibilidade.

Análises exploratórias casuais.

Custo zero de infra ociosa.

Redshift

Relatórios recorrentes e BI.

Performance bruta sob demanda alta.

Custo fixo por cluster (ou serverless base).

MÓDULO 08

AWS CloudFormation

Infraestrutura como Código

- Templates declarativos (YAML/JSON).
- Versionamento da infraestrutura.
- Automação sem painéis web.

```
Resources: DataLakeBucket: Type: 'AWS::S3::Bucket'
Properties: BucketName: 'datalake-raw'
```

Gestão do Ciclo de Vida



1. Deploy Stacks

Criação massiva em minutos.



2. Change Sets

Atualizações seguras e previsíveis.



3. Teardown

Limpeza total sem deixar rastros financeiros.